



3

Detecção de falhas em placas de aço

Objetivo: Implementar uma rede neural do tipo MLP capaz de classificar defeitos de fabricação em superfícies de placas de aço inoxidável. Tratar balanceamento de classes. Pré-processamento dos dados.

Monitorar e detectar falhas no processo produtivo industrial desempenha um papel crucial na garantia da qualidade, eficiência e segurança dos produtos. A detecção precoce de falhas durante o processo de fabricação é fundamental para evitar defeitos nos produtos acabados, minimizar o desperdício de materiais e reduzir os custos de retrabalho. Além disso, a monitorização contínua do processo produtivo industrial permite identificar tendências e padrões de desempenho ao longo do tempo, possibilitando ajustes proativos para otimizar a eficiência operacional e garantir a conformidade com as especificações de qualidade e normas regulatórias.

Os aços inoxidáveis são amplamente utilizados em uma variedade de aplicações industriais devido às suas propriedades superiores de resistência à corrosão, durabilidade e versatilidade. No entanto, o processo de produção desses materiais é complexo e envolve uma série de etapas críticas, desde a fusão dos metais até a laminação e acabamento final.

Falhas no processo, como variações na composição química, temperatura inadequada, contaminação ou imperfeições na estrutura cristalina, podem comprometer as propriedades do aço inoxidável, resultando em produtos finais de baixa qualidade ou até mesmo inseguros para uso em aplicações críticas.

Nesta perspectiva, este projeto propõe o desenvolvimento de um sistema capaz de identificar e classificar defeitos em chapas de aço inoxidável analisando sua descrição geométrica.

Detalhes sobre a base de dados são apresentados no artigo: *MetaNet*: The Theory of Independent Judges*.

3.1 DESENVOLVIMENTO E QUESTÕES

1. A base de dados está disponível no Kaggle: <https://www.kaggle.com/uciml/faulty-steel-plates> e é composta por 1941 amostras.

Para facilitar o uso na rede neural, salve em um array X as primeiras 27 colunas, que correspondem as variáveis que descrevem a forma geométrica do defeito da chapa de aço e seu contorno. As últimas sete colunas correspondem a matriz de rótulos Y no padrão do *OneHotEncoder*, que especifica os seis tipos de defeitos possíveis e um sétimo tipo considerando "outros defeitos", conforme mostra a Tabela 3.1.

2. Faça uma análise exploratória dos dados.



- i. A base de dados é consistente?
 - ii. Há dados faltantes?
 - iii. Há dados não numéricos?
 - iv. A base de dados é balanceada?
Opcional: aplique uma técnica de balanceamento dos dados.
 - v. As variáveis assumem valores plausíveis? Como é a distribuição dos dados? Há *outliers*? Faça boxplots e comente.
 - vi. Há necessidade de normalizar ou padronizar as variáveis de entrada? Justifique.
 - vii. **Opcional:** Analise o heatmap das variáveis e proponha uma estratégia para reduzir as variáveis de entrada sem perda de informação útil para o classificador.
3. Particione aleatoriamente 70% das amostras para treinar a rede neural MLP e o restante das amostras para validar o sistema.
4. Implemente uma rede neural MLP capaz de receber as variáveis de entrada que descrevem a geometria do defeito na placa e indicar a probabilidade de existência de cada possível falha.
5. Apresente o resultado fazendo considerações sobre:
- i. Como a complexidade do modelo impacta no desempenho?
 - ii. Comente sobre a estratégia de ajuste dos hiper parâmetros adotada para ajustar o modelo.
 - iii. Como a quantidade de amostras de cada classe pode influenciar no desempenho da rede neural?
 - iv. Quais variáveis de entrada são mais relevantes para o problema?



| Coluna | Variáveis |
|--------|-----------------------|
| 1 | X Minimum |
| 2 | X Maximum |
| 3 | Y Minimum |
| 4 | Y Maximum |
| 5 | Pixels Areas |
| 6 | X Perimeter |
| 7 | Y Perimeter |
| 8 | Sum of Luminosity |
| 9 | Minimum of Luminosity |
| 10 | Maximum of Luminosity |
| 11 | Length of Conveyor |
| 12 | TypeOfSteel A300 |
| 13 | TypeOfSteel A400 |
| 14 | Steel Plate Thickness |
| 15 | Edges Index |
| 16 | Empty Index |
| 17 | Square Index |
| 18 | Outside X Index |
| 19 | Edges X Index |
| 20 | Edges Y Index |
| 21 | Outside Global Index |
| 22 | Log Of Areas |
| 23 | Log X Index |
| 24 | Log Y Index |
| 25 | Orientation Index |
| 26 | Luminosity Index |
| 27 | Sigmoid Of Areas |
| | Falhas |
| 28 | Pastry |
| 29 | Z Scratch |
| 30 | K Scratch |
| 31 | Stains |
| 32 | Dirtiness |
| 33 | Bumps |
| 34 | Other Faults |

Table 3.1: Variáveis e falhas em placas de aço inoxidável.